


1A)



1B)

A->B=2	B->C=1	C->E=2
A->C=1	B->D=2	C->F=2
A->D=2	B->E=3	D->E=1
A->E=3	B->F=3	D->F=1
A->F=3	C->D=1	E->F=1

Diameter=3

E_{max}= 15

O somatório da distancia entre todos os pares de nós da rede é somar todas as células da tabela acima e multiplicar por 2 (a distancia entre A->B é a mesma entre B->A)

Average path length = $(2+1+2+3+3+1+2+3+3+1+2+2+1+1+1) \cdot 2 / (2 \cdot 15) = 1.867$

1C)

$$eA=0$$

$$eC=0$$

$$eE=1$$

$$eB=0$$

$$eD=1$$

$$eF=1$$

$$\text{Clustering } C_A=0$$

$$\text{Clustering } C_C=0$$

$$\text{Clustering } C_E=2/2=1$$

$$\text{Clustering } C_B=0$$

$$\text{Clustering } C_D=2/6=0.33$$

$$\text{Clustering } C_F=2/2=1$$

$$\text{Average local clustering } C=2.333/6=0.388$$

1D)

$$CB(A)=0$$

$$CB(C)=7$$

$$CB(E)=0$$

$$CB(B)=0$$

$$CB(D)=6$$

$$CB(F)=0$$

$$C'B(A)=0$$

$$C'B(C)=7/(5*4/2)=0.7$$

$$C'B(E)=0$$

$$C'B(B)=0$$

$$C'B(D)=6/(5*4/2)=0.6$$

$$C'B(F)=0$$

$$CC(A)=1/(1+2+2+3+3)=0.09$$

$$CC(C)=1/(1+1+1+2+2)=0.14$$

$$CC(E)=1/(1+1+2+3+3)=0.1$$

$$CC(B)=1/(1+2+2+3+3)=0.09$$

$$CC(D)=1/(1+1+1+2+2)=0.14$$

$$CC(F)=1/(1+1+2+3+3)=0.1$$

$$C'C(A)=0.09*5=0.45$$

$$C'C(C)=0.14*5=0.70$$

$$C'C(E)=0.1*5=0.5$$

$$C'C(B)=0.09*5=0.45$$

$$C'C(D)=0.14*5=0.70$$

$$C'C(F)=0.1*5=0.5$$

1E) Não

Um grafo bipartido ou Bi-grafo é um grafo cujos vértices podem ser divididos em dois conjuntos disjuntos U e V tais que toda aresta conecta um vértice em U a um vértice em V; ou seja, U e V são conjuntos independentes. Para além disso, um grafo bipartido é um grafo que não contém qualquer ciclo de comprimento ímpar.

Se o conjunto U for formado pelos vértices [A,B,C] e o conjunto V formado pelos vértices [D,E,F], podemos verificar que os nós [A,B] não se ligam a um vértice do outro conjunto (existe outros caso), logo não é Bi-grafo.

2) Para esta pergunta usei conhecimento teórico da Wikipédia

https://pt.wikipedia.org/wiki/Coeficiente_de_agrupamento

Para este exercício realizou-se 2 experiências, em que foi usado o algoritmo Erdős–Rényi.

Na primeira experiência, o grafo continha nós de baixo grau.

Na segunda experiência, o grafo continha nós de alto grau.

Realizei o cálculo do global clustering coefficient e o average cluster coeficiente dos 2 grafos.

Na experiência 2, o grafo apresentou maior global clustering coefficient do que average cluster coefficient.

Na experiência 1, foi o oposto, o grafo apresentou menor global clustering coefficient do que average cluster coefficient.

Posso concluir que, global clustering coefficient coloca maior peso nos nós com maior grau.

$C_{\text{global}} = (3 * \text{triangles}) / \text{number of triplets}$

A métrica global clustering coeficiente nos grafos em que os nós apresentam baixo grau é baixa porque o numerador da equação tende a ser pequeno, pois existe uma baixa probabilidade de se formar um triângulo fechado (B está ligado a A e C ; A está ligado a C)

Em contrapartida, nos grafos em que os nós apresentam alto grau, há uma maior probabilidade de se formarem triângulos fechados, mas como é obvio também existem muitos triplos de nós. No entanto o multiplicador de 3 no numerador da equação faz com que a o valor resultante da fração de (um número grande de triângulos *3) / (um número grande de triplos) seja maior que (um número pequeno de triângulos *3) / (um número médio de triplos)


O average cluster coefficient de toda a rede corresponde, segundo Watts e Strogatz, ao valor médio dos local cluster coefficients de todos os vértices n .

O local cluster coeficiente de um vértice (nó) num grafo mede o quão perto os vizinhos estão de serem um clique (grafo completo). Por outras palavras, pode dizer-se que o coeficiente de agrupamento local mede o grau da densidade de ligações da vizinhança de um determinado nó, isto é, corresponde ao grau com que os vizinhos de um nó se interligam. Desta forma, os grafos em que os nós apresentam menor grau tendem a que os vizinhos estejam mais próximo de formarem um grafo completo do que do que em grafos em que os nós apresentam um maior grau.

3A) Not merge

3147 airports

66679 flights



3B) Merge(sum)

A média dos voos de partida é 21.188

A média de voos para diferentes aeroportos é 11.699






Average Degree	11,699	Run	?
Avg. Weighted Degree	21,188	Run	?

3C)

Edge Overview	
Avg. Path Length	3,969 Run ?
Network Diameter	13 Run ?

3D) Merge(sum)

Source	Target	Type	Id	Label	Interval	Weight
3830	3682	Directed	276882			20.0

Nodes Edges  Configuration  Add node  Add edge  Search/Replace  Import

Id	Label	Interval	name
3830	Chicago O'Hare International Airport		

Nodes

Edges

Configuration

+

Add node

+

Add edge

Search/Replace

Import Spreadsheet

Id	Label	Interval	name
3682	Hartsfield Jackson Atlanta International Airport		

3E) Merge(sum)

name	In-Degree	Out-Degree
Frankfurt am Main Airport	238	239
Charles de Gaulle International Airport	232	237
Amsterdam Airport Schiphol	231	232

3f) Not merge

Id	Label	Interval	name	city	Betweenness Centrality
3484			Los Angeles Int...	Los Angeles	0.085182
1382			Charles de Gau...	Paris	0.071947
507			London Heathr...	London	0.061904

3g) Not merge

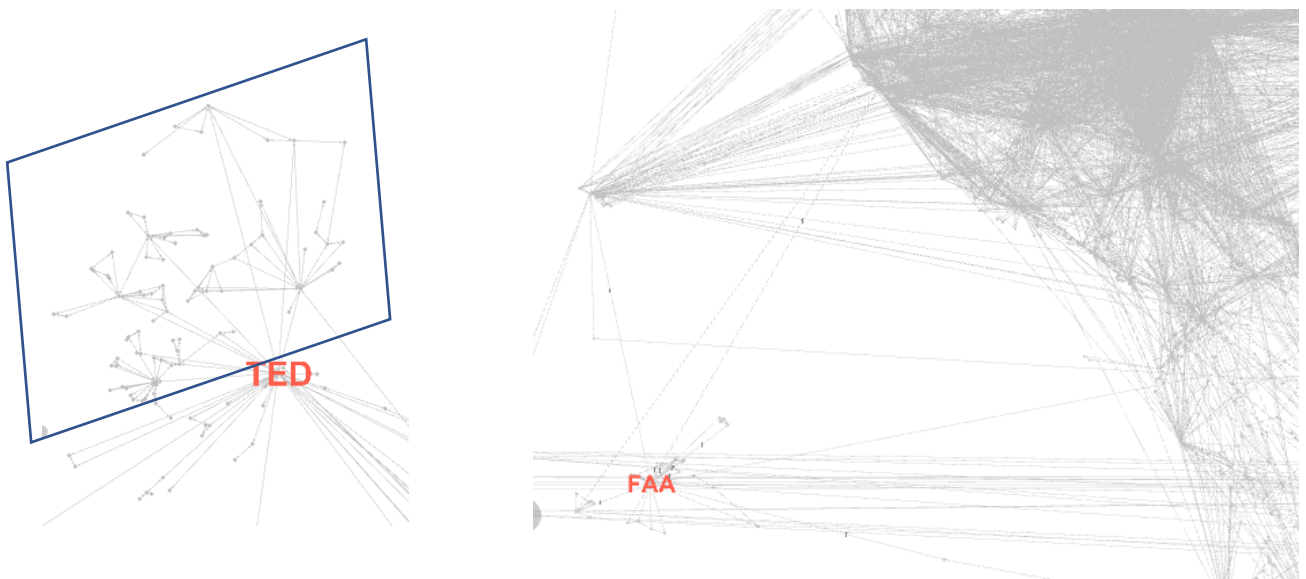
name	Betweenness Centrality	In-Degree	Out-Degree
Ted Stevens Anchorage...	0.052639	59	59

name	Betweenness Central...	In-Degree	Out-Degree
Faa'a International Airport	0.016657	38	37

A betweenness centrality capta o quanto um determinado nó (designado por u) está no meio de outros. Esta métrica é medida em função do número de caminhos mais curtos (entre qualquer par de nós nos gráficos) que passa pelo nó alvo u . Esta pontuação é moderada pelo número total de caminhos mais curtos existentes entre qualquer par de nós do gráfico.

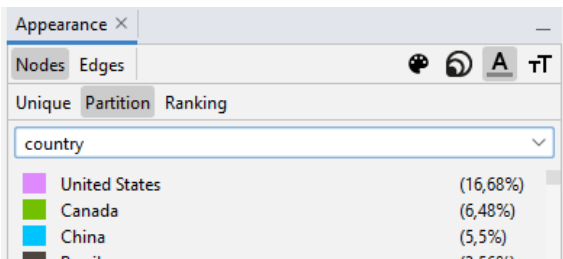
Verificamos que o Nó TED e o FAA são nós que apesar de não terem muitas ligações para outros nós, são nós que tem muita relevância na rede pois utilizam-no como caminho mais curto na rede.

Para o caso do nó TED, todos os nós dentro da caixa a azul usam o nó TED como caminho mais curto. Daí um alto valor de betweenness centrality mas um baixo valor de out degree (o nó TED não é um nó central da rede)



Da mesma forma, o Nó Faa é um nó estramamente utilizado nas ligações mais curtas por todos os nós contidos na caixa a azul da imagem anterior, ilhas Hawai (entre outros) para ligar-se à america do sul, sul de africa e sul do continente asiatico. Mas mais uma vez este nó possui um baixo valor de out degree(o nó Faa não é um nó central da rede)

3H) Not merge

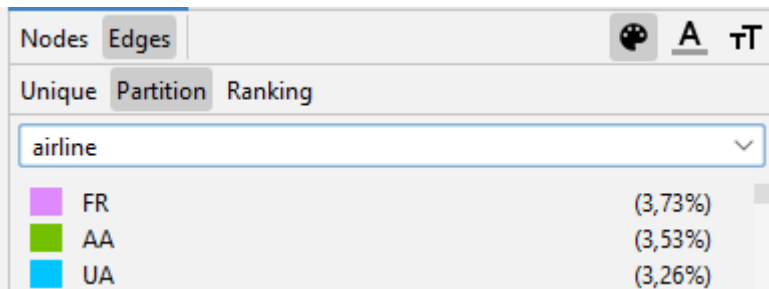


3I) Not merge



Ryanair (FR)

American Airlines (AA)


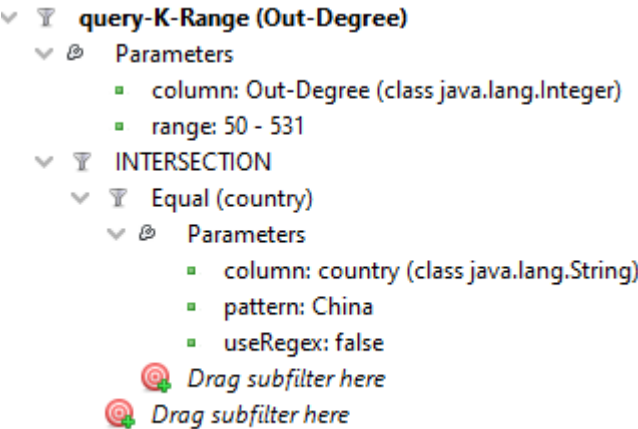
United Airlines (UA)



3J) Not merge



3K) Not merge



3L) Not merge

L-Intra Edges (country)

Parameters

column: country (class java.lang.String)

parts: [Brazil, Portugal]

Drag subfilter here

Nodes: 3147 (100% visible)

Edges: 24 (0,07% visible)

Directed Graph

3M) Not merge

Nodes: 176 (5,59% visible)

Edges: 2484 (3,73% visible)

Directed Graph

query-M-Giant Component

Equal (aid)

Parameters

column: aid (class java.lang.String)

pattern: 4296

useRegex: false

Drag subfilter here

Id	name	Closeness Ce...
1555	Leonardo da Vinci-Fiumicino Airport	0.386867

3N) Not merge

Nodes: 61 (1,94% visible)

Edges: 2284 (3,43% visible)

Directed Graph

Queries

Ego Network

Parameters

pattern: 1636

depth: 1

self: false

Drag subfilter here

Ego Network Settings

Node ID: 1636

Depth: 1

☐ With self

OK

Using depth=2

Nodes: 755 (23,99% visible)

Edges: 38583 (57,86% visible)

Directed Graph

Using depth = 3

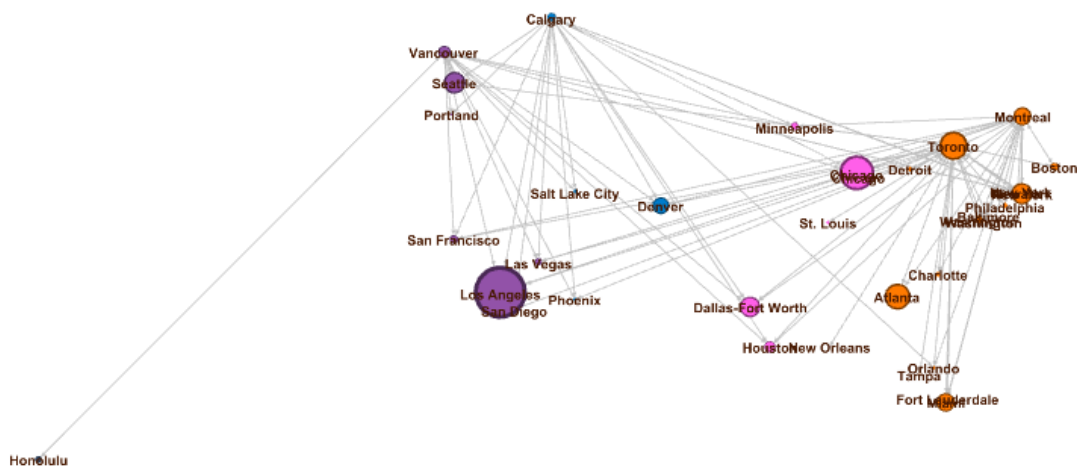
Nodes: 2376 (75,5% visible)
Edges: 63026 (94,52% visible)
Directed Graph

3 O)

Query-O-Intra Edges (country)
Parameters
column: country (class java.lang.String)
parts: [Canada, United States]
Range (Out-Degree)
Parameters
column: Out-Degree (class java.lang.Integer)
range: 100 - 915
Drag subfilter here


Nodes: 166 (5,27% visible)
Edges: 470 (0,7% visible)
Directed Graph

O tamanho do Nó reflete a betweenness centrality, enquanto que no label consta a cidade. As várias cidades estão de diferentes cores, mostrando os vários fusos horários.



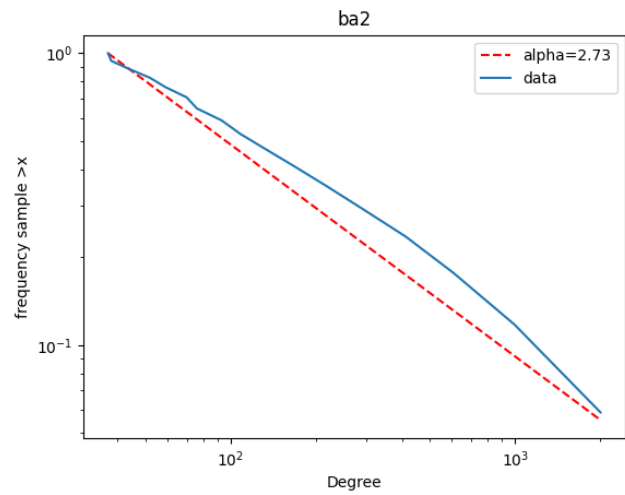

Os códigos das funções dos próximos exercícios tiveram inspiração própria.

Exe6)



Ex8) Para calcular a função cumulativa da distribuição, utilizei uma função de Python que realiza este cálculo de forma automática

`fit.power_law.plot_ccdf(linestyle='--', color='r')`



Trabalho realizado por: Lázaro Costa